

RとQuartoではじめるデータサイエンス《2026》

#2 Rの基本的な操作方法(1)

荻谷千尋

Wed, 15, Apr, 2026

目次

1. 前回の振り返り
2. データフレームの構造と型
3. データの抽出
4. データの要約と集計
5. 生成AIを活用する
6. Rの構造：base R と modern R(tidyverse)の関係

0. 本日の目標

1. データフレームの基本的な構造（行・列・変数）を理解する
2. データの型（数値・文字・ファクターなど）の違いを**なんとなく**理解する
3. データの抽出・除外についての基本的な操作を行ってみる
4. データを簡単に計算し、その結果を図にしてみる（**詳しい説明、理解は次週以降**）
5. 生成AIの注意点を理解してRの補助ツールとして活用する
6. base Rとmodern Rの関係を**なんとなく**理解する

2. データフレームの構造と型

- Rの基本操作：列名中心
 - → 列名を**わかりやすく、かつ、一意な名前を付けることが重要** Cf. `colnames()`関数
- データフレーム = データを表の形でまとめたもの
 - **明確な列名とそれに従った値からなる**
 - 行 (row) : 1つの観測 (例: 1羽のペンギン)
 - 列 (column) : 1つの変数 (例: 体重・種類)
- 型によって「できる操作」が異なる
 - 数値: 計算に向いている
 - 文字: 分類に向いている
 - カテゴリ: 分類に使われるデータ (順序を持つこともある)
- `skim()`関数によるデータの特徴・型の把握

3. データの抽出

- `filter()`関数: 指定した変数のデータのみ残す
- `filter_out()`関数: 指定した変数のデータを除外する
- 欠損値
 - Rは**NAの扱いを明示しないと計算しない仕様**

- 欠損値の除外：drop_na()関数が基本
- 欠損値の置き換え：replace_na()関数

4. データの要約と集計（基本編）

- 平均値を算出する：summarise()関数とmean()関数を組み合わせる
 - `summarise(avg_body_mass = mean(body_mass))`
- グループごとの平均値を算出する：group()関数
 - `group_by(species)`

5. 生成AIを活用する

(1) 生成AIの利点を知る

- コードと生成AIは相性がよい

(2) 生成AIの限界を知る

- 古い情報・不正確な情報や、存在しない関数、間違ったコードを出すことがある
- AIは目的や問い、仮説を立てることはできない
 - → 何を分析したいかは自分で考える必要がある

6. Rの構造：base R と modern R(tidyverse)の関係

(1) 3層構造

- Packages
 - 目的別に追加するツール：**家具や家電**
- modern R：tidyな（整然とした）R:
 - 近年の改良で、より読みやすく・便利になった文法：**家の骨組み・壁・柱、設計の考え**
 - 関数は動詞ベース（何をすることがわかりやすい）
 - 例：filter; select Cf. base R: subset（数学の「部分集合」に由来）
- base R：R言語そのもの：**家の基礎部分**

(2) パイプ処理

- |> または %>%
- 前の結果を次の関数に渡して、処理を順番につなげる役割を担う
 - **コードはオブジェクト（データ）から始まる**
 - **何をどうしたいのかが明確**（書きやすく、読みやすい）
 - → コードを単純化でき、上から順に読めるコードになる

宿題

授業の感想：

- 回答先：Google Forms
- 締め切り：4月17日
（金）23時59分

演習：

- 内容：授業内で課した演習①～④
- ファイル：演習の該当箇所を抜き出すのではなく、**qmdファイル**をそのまま提出
 - ファイル名：どこかに***氏名を特定できる文字**を入れて下さい（例：inClassExercise_**kariya**.qmd）
- 回答先：dropbox
- 締め切り：4月20日（月）23時59分