RとQuartoではじめるデータサイエンス 2024

役立つサイト

苅谷 千尋

12, Jun, 2024

Note 随時更新します

Warning 以下のサイトは有益ですが、今となっては古い情報も交じっています。まずは指定の教科書を しっかりと理解することから始めましょう。いずれ教科書も古くなりますが、教科書内におい ては、相互に矛盾する記述はないため、理解しやすいです。

0. 教科書

- 《訳書》『データ分析のためのデータ可視化入門』
- 《原著》Data Visualization: A practical introduction
- 《書評》『データ分析のためのデータ可視化入門』と最近の R グラフィックスパッケージ事情

1. 基本

Note 1から5までの基本的な内容は、この授業内で理解して欲しい範囲です(3の(5)と(6)は除く)

1. 全般

- 私たちのR:ベストプラクティスの探求
- 実験データの解析はエクセルではなくRを使った方がその研究は成功する
- Statistics Globe
- Tidyverse Skills for Data Science -Introduction to the publ package

2. 初学者

- R初学者のためのtidyverse100本ノック
- R初学者からよく質問されること
- R Studio: Beginners

3. ggplot

(1) ggplot

- ggplot2(公式サイト)
- 統計学2: ggplot2入門
- ggplot2の辞書
- 図から逆引きするgeom_*関数 (ggplot2)
- ggplot2における 軸関連のコントロール〜逆引き的ミニまとめ〜
- •【R】ggplot2で相関行列ヒートマップを描く

(2) アノテーション

- ggplot2のアノテーション技法
- ggplot2を使って、注釈を入れる-1
- FAQ: Annotation

- Beautifully Annotated: Enhancing your ggplots with Text
- Rの{gghighlight}で折れ線グラフをいろいろな条件でハイライトするグループを決定したいメモ

(3) カラーパレット

- ggsci
- fishualize Paracanthurus_hepatus
- R Color Palettes
- colorblindr

(4) テーマ

ggthemes

(5) ラッパー

• ggmosaic (公式サイト)

(6)アニメーション

• 【R, gganimate】COVID-19感染者数Top 5をアニメーションで可視化する

4. テーブル

- Introduction to Creating gt Tables (gt公式サイト)
- •【R】ガチできれいなTableを作れるgtパッケージとは?
- •【R】データ要約ガチ勢のためのgtsummaryで表を書こう
- 回帰モデルの結果をキレイに表示する(gtsummaryパッケージtbl_regression関数)[R]

5. 出力方法

- R Markdown クックブック
- TinyTeX
- .qmd を超お手軽完全無料パブリッシュできる Quarto Pub を使ってみる
- Quarto Pub
- Create Your Website with Quarto
- How to create a dashboard using Quarto

6. マップ

- leafletではじめるRによる地図プロット はじめに
- Leaflet Map View
- Leaflet Maps with CSV Data · 公式サイト
- ggmap・公式サイト
- Thematic maps with cartography · 公式サイト
- Rで国土地理院 基盤地図情報データを扱う
- ggplot2 で沖縄をずらして日本地図を描きたい
- •[小ネタ] R でコロプレス図 (色分け地図) をなるべく簡単に描く

7. コミュニティ

• r-wakalang へようこそ

• Tokyo.R

8. インストール他

- WindowsでのR/RStudioのインストール
- localeを日本語(ja JP.UTF-8)にする
- ものすごくどうでもいい覚え書き: RStudioのエディタ・テーマ総ざらえ
- Modern CSV · 公式

Ⅱ. 研究分野別

1. 社会科学

- siPlot
- 社会学のデータ分析でよくある処理
- ・ 総選挙データの可視化
- quanteda:衆議院外務委員会の議事録
- 西山 他『計量経済学』のためのR
- Introduction to Econometrics with R
- コレスポンデンス分析の同時布置図は本当に使えないのか?
- Julia Silge

2. 医学・生物学

- 疫学や公衆衛生に関わる業務のためのR
- 医学統計でよく使うRパッケージ
- Rtigraphではじめる生物ネットワーク解析
- ・【RNA-seq】RNA-seq解析を徹底的に解説!Part2_{発現変動解析(DEG解析)}
- Bioconductor Genomicデータ解析ツール群
- Introduction to 'gggenes'
- Prevelence of SARS-CoV-2 Variants of Concern in Aoteoroa New Zealand

3. 心理学

• 無料統計ソフトRで心理学

4. 自然科学

- Democratizing Historical Weather Data Analysis with R
- 気象庁提供の潮位表、過去の気象データをRで読み込む
- 「昔はこんなに暑くなかった」をR言語で可視化する

<u>5. スポーツ</u>

• Using the R and the Tidyverse to analyze Joel Embiid's Player Stats

Note この他、専門分野ごとに多くの専門書が出版されています

Ⅲ. 分析手法

1. ネットワーク分析

- bob3's blog
- The Jose M Sallan static website

2. テキストマイニング

• RとMeCabによる日本語テキストマイニングの前処理

IV. データ入手

1. 日本政府統計の総合窓口(e-stat)

- Rで日本の統計データを効率的に取得しよう
- みんなのデータサイエンス:e-Stat
- Rでe-statからxls (xlsx) ファイルをダウンロードするときにうまくいかなかったときに対処したメモ

V. 前処理(データ加工)

1. 前処理全般

- Rで読むExcelファイル
- 複数のファイルを一度に読みこむ方法
- 「Rによるデータクリーニング実践」をやってみた
- Style guide
- 住所や年号、漢数字のデータ操作を楽にするRパッケージをCRANに登録しました
- Rでデータフレーム ⇔ リスト の変換

2. 時間処理

- lubridate (公式サイト)
- 【R前処理講座32】{lubridate}:時間処理【tidyverse】
- lubridateパッケージ入門

3. 同一処理

• Rでforループで大量に{ggplot2}でグラフを書きたい (purrr::map()も添えて)

VI モデル

- Tidymodelsをシンプルに使う
- 【R】tidymodelsとworkflowを中心に~機械学習のフレームワーク~(その1)
- tidymodelsとDALEXによるtidyで解釈可能な機械学習
- tidymodels (公式サイト)
- R言語の基礎 #04、データの回帰分析・相関分析(diamondsデータ)
- purrrとbroomで複数の回帰モデルを効率的に管理する
- 回帰分析ではlm()ではなくestimatr::lm_robust()を使おう / TokyoR100
- 固定効果モデルについて / パネルデータ分析
 - 。【R】固定効果モデルの推定がめっちゃ速いパッケージ { fixest }

o ggfixest